

假设有一个音频数据，可以看做M个不同类型的异响+汽车正常行驶的背景声音，异响分量符合低秩假设，请你构造等效约束优化问题，将这M个异响分量分离出来，首先进行数学建模。然后在后台调试Python程序，这个程序需要包含信号生成，信号分离，分离效果评估。你可以利用stft进行预处理，也可以尝试利用相位信息。最终，给我完整的数学推导流程，以及完整的程序

I'll first formalize identifiability assumptions for single-channel separation, then build a computable STFT-domain low-rank constrained model with background residuals. I'll validate it using a runnable Python simulation covering synthesis, separation, phase-based reconstruction, and SDR/SIR/SAR/correlation metrics.

I have a runnable grouped-NMF structure using a background dictionary plus one low-rank dictionary per abnormal sound. Debugging found a frequency-band mask indexing issue, now being fixed before rerunning the full experiment.

Thought for 19m 37s >

下面给出一个**可辨识的数学模型**与一个我已跑通的 Python 仿真程序。完整脚本也已保存为：

下载完整 Python 脚本

我在脚本默认参数  $M=3$ ,  $fs=8000$ ,  $seed=42$  下跑通后，示例评估结果约为：

| source | SI_SDR_dB | corr  | SDR_proj_dB | SIR_proj_dB | SAR_proj_dB |
|--------|-----------|-------|-------------|-------------|-------------|
| knock  | 5.98      | 0.893 | 5.98        | 28.15       | 6.0         |
| rattle | 11.11     | 0.963 | 11.11       | 33.57       | 11.1        |

## 1. 信号模型

假设单通道汽车音频为

$$x[n] = b[n] + \sum_{m=1}^M a_m[n],$$

其中：

$$b[n]$$

是汽车正常行驶背景声，例如发动机、胎噪、风噪；

$$a_m[n]$$

是第  $m$  类异响，例如啸叫、敲击、rattling 等。

对  $x[n]$  做 STFT:

$$X_{ft} = \mathcal{S}\{x[n]\}_{ft},$$

因为 STFT 是线性变换, 所以有

$$X_{ft} = B_{ft} + \sum_{m=1}^M A_{m,ft} + E_{ft},$$

其中  $E_{ft}$  表示建模误差。实际分离时, 通常不直接对复数 STFT 施加低秩, 而是对幅值谱或功率谱施加低秩假设:

$$V = |X| \in \mathbb{R}_+^{F \times T}.$$

令

$$L_0 \approx |B|, \quad L_m \approx |A_m|, \quad m = 1, \dots, M.$$

于是有幅值谱近似分解:

$$V \approx L_0 + \sum_{m=1}^M L_m.$$

## 2. 低秩异响假设

异响分量满足低秩假设, 即

$$\text{rank}(L_m) \leq r_m, \quad m = 1, \dots, M.$$

这意味着第  $m$  类异响的幅值谱可以由少数几个谱模板和时间激活组合得到:

$$L_m = W_m H_m,$$

其中

$$W_m \in \mathbb{R}_+^{F \times r_m}, \quad H_m \in \mathbb{R}_+^{r_m \times T}.$$

这里:

$$W_m$$

表示第  $m$  类异响的频率模板;

$$H_m$$

表示第  $m$  类异响的时间激活。

因此:

$$\text{rank}(W_m H_m) \leq r_m.$$

背景声也可以用低秩或较高秩模型描述:

$$L_0 = W_0 H_0, \quad \text{rank}(L_0) \leq r_0.$$

## 3. 为什么仅有低秩不够?

单通道分离中，只有

$$V \approx L_0 + L_1 + \cdots + L_M$$

和

$$\text{rank}(L_m) \leq r_m$$

通常是不够的。因为多个低秩矩阵之间可以互相“挪动能量”，导致分解不唯一。

所以需要加入额外约束，例如：

1. 不同异响有不同频带或谱模板先验；
2. 异响通常是间歇性的，所以其时间激活  $H_m$  可加稀疏约束；
3. 背景声与异响在谱空间上尽量不相干；
4. 每类异响的  $\text{rank } r_m$  较小；
5. 对  $W_m$  加频率支撑 mask。

设  $P_m \in \{0, 1\}^{F \times r_m}$  是第  $m$  类异响的频率支撑约束，例如啸叫在 1.3 kHz 到 1.8 kHz 附近，则要求：

$$W_m = P_m \odot W_m.$$

#### 4. 等效约束优化问题

原始低秩约束优化可以写成：

$$\begin{aligned} \min_{\{L_j\}_{j=0}^M} \quad & \frac{1}{2} \left\| V - \sum_{j=0}^M L_j \right\|_F^2 + \sum_{m=1}^M \mu_m \|L_m\|_1 \\ \text{s.t.} \quad & L_j \geq 0, \quad j = 0, \dots, M, \\ & \text{rank}(L_j) \leq r_j, \quad j = 0, \dots, M, \\ & (1 - P_m) \odot L_m = 0, \quad m = 1, \dots, M. \end{aligned}$$

其中  $\|L_m\|_1$  或  $\|H_m\|_1$  用来鼓励异响激活稀疏。

也可以写成核范数松弛形式：

$$\begin{aligned} \min_{\{L_j\}_{j=0}^M} \quad & \frac{1}{2} \left\| V - \sum_{j=0}^M L_j \right\|_F^2 + \sum_{j=0}^M \tau_j \|L_j\|_* + \sum_{m=1}^M \mu_m \|L_m\|_1 \\ \text{s.t.} \quad & L_j \geq 0, \\ & (1 - P_m) \odot L_m = 0, \quad m = 1, \dots, M. \end{aligned}$$

但是程序中采用更直接的非负低秩分解形式：

$$L_j = W_j H_j.$$

于是得到等效的约束 NMF 问题：

$$\begin{aligned} \min_{\{W_j, H_j\}} \quad & \frac{1}{2} \left\| V - \sum_{j=0}^M W_j H_j \right\|_F^2 + \sum_{m=1}^M \lambda_m \|H_m\|_1 \\ \text{s.t.} \quad & W_j \geq 0, \quad H_j \geq 0, \\ & W_m = P_m \odot W_m, \quad m = 1, \dots, M, \\ & \|w_{jk}\|_1 = 1. \end{aligned}$$

其中  $\|w_{jk}\|_1 = 1$  用来消除尺度不唯一性:

$$W_j H_j = (W_j D)(D^{-1} H_j).$$

## 5. 乘法更新推导

将所有  $W_j$  拼接为

$$W = [W_0, W_1, \dots, W_M],$$

将所有  $H_j$  按行拼接为

$$H = \begin{bmatrix} H_0 \\ H_1 \\ \vdots \\ H_M \end{bmatrix}.$$

令

$$\widehat{V} = WH.$$

目标函数为:

$$J(W, H) = \frac{1}{2} \|V - WH\|_F^2 + \langle \Lambda, H \rangle,$$

其中  $\Lambda$  对背景激活行为 0, 对异响激活行为  $\lambda_m$ 。

对  $H$  求梯度:

$$\nabla_H J = W^T WH - W^T V + \Lambda.$$

将梯度拆成正负部分:

$$\nabla_H^+ = W^T WH + \Lambda,$$

$$\nabla_H^- = W^T V.$$

得到乘法更新:

$$H \leftarrow H \odot \frac{W^T V}{W^T WH + \Lambda + \varepsilon}.$$

对  $W$  求梯度:

$$\nabla_W J = WHH^T - VH^T.$$

对应乘法更新为:

$$W \leftarrow W \odot \frac{VH^T}{WHH^T + \varepsilon}.$$

然后进行频带约束投影：

$$W_m \leftarrow P_m \odot W_m.$$

最后归一化每个  $W$  的列，并把尺度吸收到  $H$  中。

## 6. 利用相位信息重构时域信号

NMF 分离得到的是每个源的幅值谱估计：

$$\hat{L}_j.$$

为了恢复复数 STFT，可以使用类似 Wiener mask 的相位感知重构：

$$M_j(f, t) = \frac{\hat{L}_j(f, t)^p}{\sum_{k=0}^M \hat{L}_k(f, t)^p + \varepsilon}.$$

程序中取  $p = 2$ ，即功率谱比例掩膜：

$$\hat{A}_j(f, t) = M_j(f, t)X(f, t).$$

这样每个源继承混合信号  $X$  的相位：

$$\angle \hat{A}_j(f, t) = \angle X(f, t).$$

最后 ISTFT 得到时域估计：

$$\hat{a}_j[n] = \mathcal{S}^{-1}\{\hat{A}_j\}.$$

这个重构也可以从下面的复数约束优化得到：

$$\begin{aligned} \min_{\{\hat{A}_j\}} \quad & \sum_{j=0}^M \frac{|\hat{A}_j(f, t)|^2}{\hat{L}_j(f, t)^2 + \varepsilon} \\ \text{s.t.} \quad & \sum_{j=0}^M \hat{A}_j(f, t) = X(f, t). \end{aligned}$$

对每个时频点求解，可得：

$$\hat{A}_j(f, t) = \frac{\hat{L}_j(f, t)^2}{\sum_{k=0}^M \hat{L}_k(f, t)^2 + \varepsilon} X(f, t).$$

## 7. 完整 Python 程序

<> Python



Run

```
import os
from dataclasses import dataclass
from typing import List, Dict, Tuple

import numpy as np
from scipy import signal
from scipy.io import wavfile
```